

Содержание

Введение	6
1 Алгоритмы классификации данных	7
1.1 Метод опорных векторов	8
1.2 Метод k-ближайших соседей	10
1.3 Наивный байесовский классификатор	11
2 Разработка программы для классификации с использованием библиотеки Scikit-learn	13
2.1 Обзор существующих библиотек для машинного обучения	13
2.1.1 Scikit-learn	13
2.1.2 Theano	14
2.1.3 TensorFlow	14
2.2 Алгоритм работы и структура программы	15
2.3 Визуализация данных	17
3 Классификация температурных данных компьютерного моделирования	19
3.1 Данные для классификации	19
3.2 Частотный анализ классифицируемых данных	20
3.3 Результаты классификации моделей с опухолью радиусом 0.5 см	23
3.4 Результаты классификации моделей с опухолью радиусом 0.75 см	24
3.5 Результаты классификации для всех моделей вместе	25
Заключение	27
Список литературы	28
Приложение А	33

Введение

На протяжении всего времени существования человечества проблема возникновения, исследования и лечения различных заболеваний у человека является важной задачей медицинской деятельности. Особенно это касается онкологических заболеваний. На сегодняшний день нет четкой причины, по которой люди заболевают раком, но существует множество способов ранней диагностики таких заболеваний [4].

В данной работе рассматривается использование результатов моделирования, соответствующих методике микроволновой радиотермометрии молочных желез на основе работы специального диагностического комплекса РТМ-01-РЭС [27]. Также рассматриваются популярные алгоритмы классификации данных и библиотеки для языка программирования Python, реализующие данные алгоритмы.

Главной целью работы является проведение исследования влияния размеров опухоли на точность диагностики раковых заболеваний на основе данных микроволновой радиотермометрии, полученных в ходе компьютерного моделирования. Так как проведение классификации только на температурных данных может не дать хорошего результата, необходимо выявить какой из алгоритмов будет лучше работать с разными размерами опухоли и вариациями остальных параметров.

1 Алгоритмы классификации данных

Классификация данных состоит из прогнозирования определенного результата на основе уже известных данных. Чтобы предсказать результат, алгоритм обрабатывает данные, содержащие набор атрибутов и соответствующий каждому набору результат, обычно называемый атрибутом прогнозирования цели или классом [5]. Формируется модель алгоритма, которая пытается обнаружить отношения между атрибутами, которые позволили бы предсказать результат [6]. Такая процедура называется обучением модели, а набор данных, используемый для этого – тестовой выборкой [8].

Следующим шагом после обучения модели является прогнозирование – процедура определения класса, при которой используется набор данных с неизвестными классами. Такой набор данных, который содержит тот же набор атрибутов, за исключением атрибута прогнозирования, часто называют тестовой выборкой [15].

Алгоритм анализирует входные данные и выдает прогноз. Точность прогноза определяет, насколько «хорош» алгоритм. Например, в медицинской базе данных обучающий набор должен иметь соответствующую информацию о пациенте, записанную ранее, где атрибутом прогноза является наличие или отсутствие у пациента проблем со здоровьем.

Для определения того, какой именно алгоритм использовать для конкретной задачи можно воспользоваться схемой, изображенной на рисунке 1. Исходя из того, что в текущей задаче используется не тестовая информация и имеется 160 примеров, то были выбраны алгоритмы SVM, k-ближайших соседей и наивный байесовский классификатор, описанные ниже.

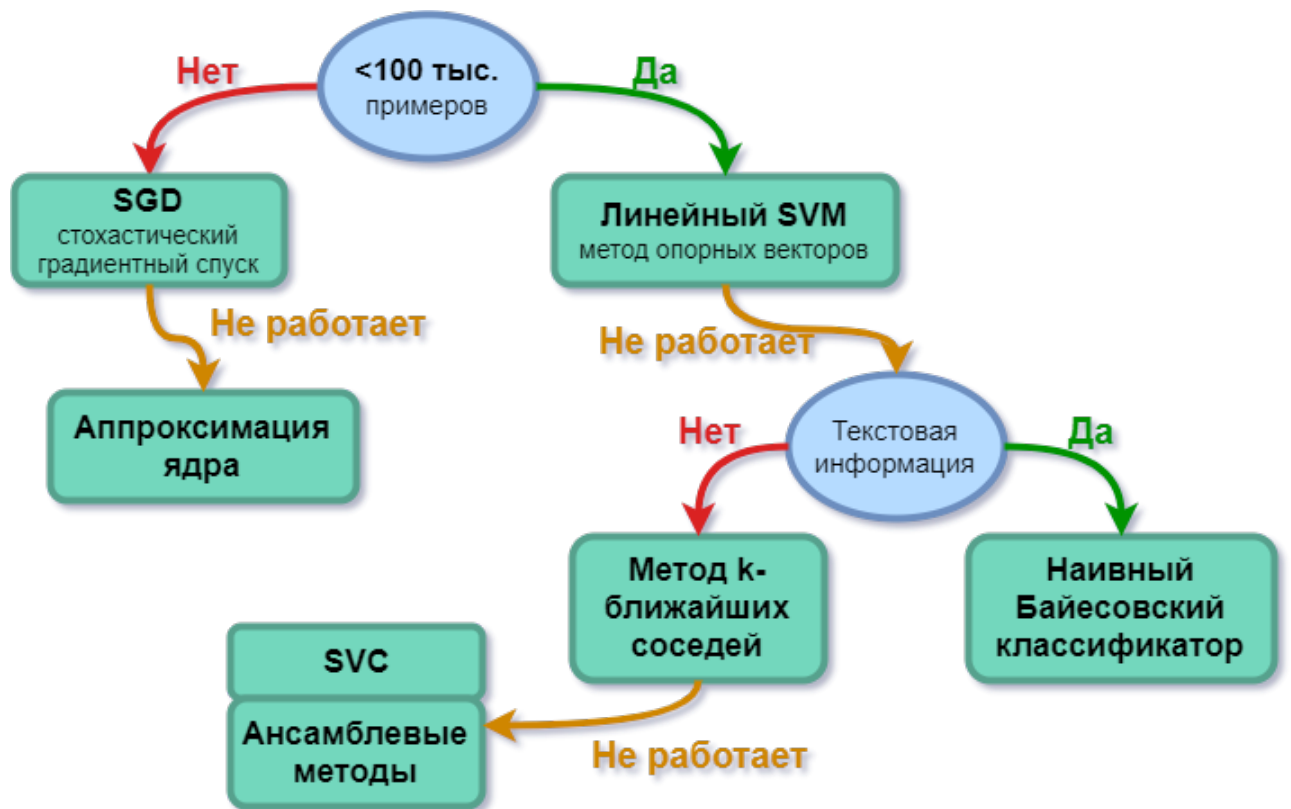


Рисунок 1 – Схема для определения алгоритма классификации для конкретной задачи

1.1 Метод опорных векторов

Метод опорных векторов или SVM – это метод статистической классификации [?]. Он широко используется для задач различного рода и хорошо себя в них показывает [3].

Основной идеей метода является представление атрибутов данных в виде векторов и переход в пространство более высокой размерности, чем получившееся на этапе представления векторами. Затем ищется гиперплоскость с максимальным зазором в пространстве между объектами разных классов [33] [11].

На рисунке 2 показан пример классификации методом SVM. Красной линией выделена как раз та самая гиперплоскость, четко разделяющая объекты разных классов друг от друга.




Рисунок 2 – Пример классификации методом SVM

Алгоритм может использоваться с одним из следующих видов ядер [3]:

- Полиномиальное (однородное) $k(x, x') = (x \cdot x')^d$;
- Полиномиальное (неоднородное) $k(x, x') = (x \cdot x' + 1)^d$;
- Радиальная базисная функция $k(x, x') = \exp(-\gamma \|x - x'\|^2)$, для $\gamma > 0$;
- Радиальная базисная функция Гаусса $k(x, x') = \exp\left(-\frac{\|x - x'\|^2}{2\sigma^2}\right)$;
- Сигмоид $k(x, x') = \tanh(kx \cdot x' + c)$.

1.2 Метод k-ближайших соседей

Алгоритм k-ближайших соседей является простым статистическим алгоритмом обучения, в котором объект классифицируется своими соседями. При классификации таким методом объект относится к классу, наиболее распространенному среди его k-ближайших соседей [32] [35]. Пример классификации приведен на рисунке 3, где в качестве классифицируемого объекта используется прямоугольник и существует несколько объектов известных классов – белые точки и черные. Замерив расстояние от объекта до его соседей с различными классами и основываясь на методе k-ближайших соседей данный объект будет отнесен к классу черных точек, а не белых.




Рисунок 3 – Пример классификации методом k-ближайших соседей

При нахождении атрибутов учитывается значимость атрибутов и часто применяется прием растяжения осей, демонстрируемый в формуле (1). Использование данного приема снижает ошибку классификации.

$$D_E = \sqrt{3(x_A - y_A)^2 + (x_B - y_B)^2}, \quad (1)$$

где x_A, y_A – значения атрибута А в наборе данных, x_B, y_B – значения атрибута В.

Данный алгоритм возможно применять как для данных с маленьким количеством атрибутов, так и с достаточно большим. Важным моментом при работе с алгоритмом является определение функции расстояния между значениями. Примером такой функции может быть евклидово расстояние – формула (2).

$$D_E = \sqrt{\sum_i^n (x_i - y_i)^2}, \quad (2)$$

где x_i, y_i – значения атрибутов в наборе данных.

1.3 Наивный байесовский классификатор

Наивный байесовский классификатор является простым вероятностным классификатором и основывается на применении теоремы Байеса со строгими предположениями о независимости [32]. Хотя наивный байесовский классификатор редко применим к большинству реальных задач, но зачастую в определенных задачах он демонстрирует хорошие результаты и часто конкурирует с более сложными методами, такими как SVM и классификационным деревьями [8]. Классификация данным методом очень зависит от распределения зависимостей атрибутов, а не от самих зависимостей [25].

Вероятностная модель классификатора:

$$p(C|F_1, \dots, F_n) = \frac{p(C)p(F_1, \dots, F_n|C)}{p(F_1, \dots, F_n)}, \quad (3)$$

где C – класс модели, а F_i – классифицируемые модели [8].

Использование формулы (3) при классификации дает минимально значение среднего риска или математического ожидания ошибки:

$$R(a) = \sum_{y \in Y} \sum_{\varsigma \in Y} \lambda_y P_y P_{x,y} \{a(x) = \varsigma | y\}, \quad (4)$$

где λ_y – цена ошибки при отнесении объекта класса Y к какому-либо другому классу.

2 Разработка программы для классификации с использованием библиотеки Scikit-learn

2.1 Обзор существующих библиотек для машинного обучения

На текущий момент существует множество готовых реализаций алгоритмов машинного обучения и не имеет смысла делать то же самое с нуля, если задача не имеет каких-то особенностей, делающих невозможным использование готовых библиотек. Каждая из библиотек, рассматриваемых в работе, хороша в своей области, успешно используется в решении задач и проверена временем. Рассмотрим некоторые из популярных библиотек для языка программирования Python.

2.1.1 Scikit-learn

Scikit-learn – это одна из самых популярных библиотек для языка Python, в которой реализованы основные алгоритмы машинного обучения, такие как классификация различных типов, регрессия и кластеризация данных. Библиотека распространяется свободно и является бесплатной для использования в своих проектах [33].

Данная библиотека создана на основе двух других – NumPy и SciPy, имеющих большое количество готовых реализаций часто используемых математических и статистических функций. Библиотека хорошо подходит для простых и средней сложности задач, а также для людей, которые только начинают свой путь в изучении машинного обучения.

2.1.2 Theano

Theano – это библиотека, в которой содержится базовый набор инструментов для машинного обучения и конфигурирования нейросетей. Так же у данной библиотеки есть встроенные методы для эффективного вычисления математических выражений, содержащих многомерные массивы [33].

Theano тесно интегрирована с библиотекой NumPy, что дает возможность просто и быстро производить вычисления. Главным преимуществом библиотеки является возможность использования GPU без изменения кода программы, что дает преимущество при выполнении ресурсоемких задач. Также возможно использование динамической генерации кода на языке программирования C [24].

2.1.3 TensorFlow

Самой популярной и масштабной по применению является библиотека TensorFlow, используемая для глубокого машинного обучения [22]. Библиотека разрабатывается в тесном сотрудничестве с компанией Google и применяется в большинстве их проектов где используется машинное обучение. Библиотека использует систему многоуровневых узлов, которая позволяет вам быстро настраивать, обучать и развертывать искусственные нейронные сети с большими наборами данных.

Библиотека хорошо подходит для широкого семейства техник машинного обучения, а не только для глубокого машинного обучения. Программы с использованием TensorFlow можно компилировать и запускать как на CPU, так и на GPU. Также данная библиотека имеет обширный встроенный функционал логирования, собственный интерактивный визуализатор данных и логов [29].

2.2 Алгоритм работы и структура программы

Целью разработки программы была классификация температурных данных с разными разамирами опухоли и графическое представление полученных результатов. Блок-схема получившейся программы представлена на рисунке 4.

На первом этапе температурные данные считываются из CSV-файла с помощью библиотеки Pandalas. Название папки с файлом моделей определенного размера опухоли хранится в отдельной переменной. Затем производится создание и обучение моделей классификации методов SVM, k-ближайших соседей и наивного байесовского классификатора на данных обучающей выборки.

Следующим этапом после обучения идет прогнозирование или классификация с использованием данных тестовой выборки. После получения результирующих классов из модели необходимо сравнить их с теми, которые уже известны для определения точности работы алгоритма. После обработки результатов классификации полученные данные отображаются на круговых диаграммах отдельно для каждого алгоритма. Полный код получившейся программы приведен в приложении (листинг А.1).



Рисунок 4 – Блок-схема программы для классификации температурных данных

2.3 Визуализация данных

Для визуализации данных моделей и результатов классификации была выбрана библиотека для языка Python Matplotlib. Данная библиотека позволяет строить графики, гистограммы, круговые диаграммы, карты распределения и 3D-объекты (рисунок 5) [24]. Возможна детальная настройка цветов линий, надписей, расположения элементов и подписей к графикам, осям и значениям.

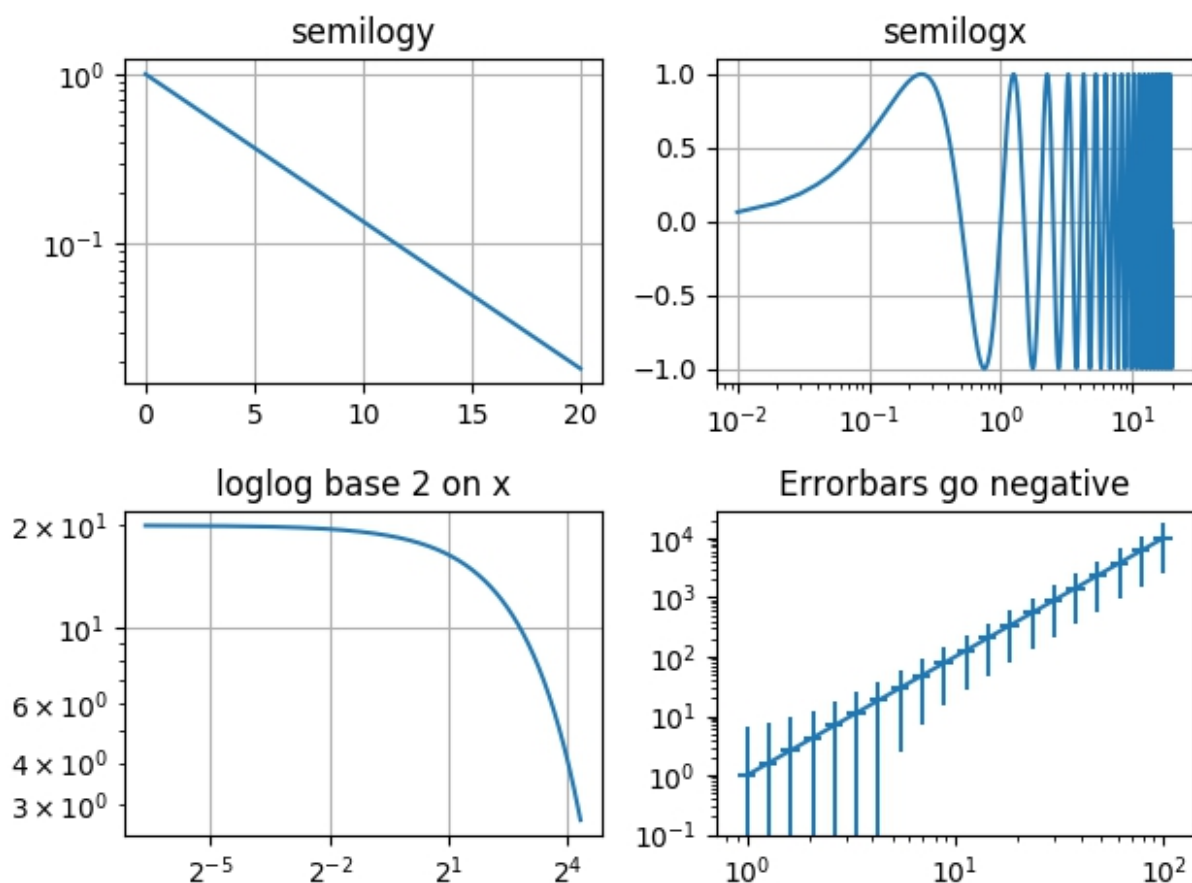


Рисунок 5 – Примеры графиков, построенных с помощью библиотеки Matplotlib

Библиотека содержит множество разных способов построения и отображения объектов, имея многослойную структуру. За счет этого имеется возможность накладывать графики друг на друга. Графики, построенные через Matplotlib отображаются в отдельном окне при запуске программы из тер-

минала, при использовании Jupyter Notebook отображаются прямо в тексте. Также имеется возможность встроить графику в программу с графическим интерфейсом на Python, реализованную с помощью библиотеки Tkinter.

3 Классификация температурных данных компьютерного моделирования

3.1 Данные для классификации

В работе использовались данные компьютерного моделирования яркостной температуры молочных желез больных и здоровых пациентов. Данные были представлены в виде девяти значений температуры на поверхности кожи и девяти значений внутренней температуры, согласно методике обследования методом радиотермометрии [4] [1]. Схема расположения точек при замере температур представлена на рисунке 6 [19]. Отдельным атрибутом является класс модели. Для здоровых моделей значения класса было равно нулю, а для больных – единице. Исходя из количества классов, классификацию в данной работе можно считать бинарной.




Рисунок 6 – Пример данных температурных данных компьютерного моделирования, где в столбце «target» здоровые — «0», больные — «1»

Для исследования были взяты температурные данные моделей с радиусом опухоли 0.5 см и 0.75 см. Данные были представлены в виде двух CSV-файлов, в которых находилось по 160 моделей для каждого размера опухоли соответственно (рисунок 7). Одна половина моделей состояла из здоровых пациентов, а другая из больных. На подготовительном этапе данные были разбиты на обучающую и тестовую выборки в соотношении один к четырем.

0ртм	1ртм	2ртм	3ртм	4ртм	5ртм	6ртм	7ртм	8ртм	0ик	1ик	2ик	3ик	4ик	5ик	6ик	7ик	8ик	target
33.5	33.1	33.7	32.6	32.7	33.2	33.4	33.2	33.3	29.8	29.9	30.2	30.0	30.0	31.1	29.4	29.6	29.8	0
33.7	32.8	33.3	33.2	33.5	33.5	33.2	32.9	32.4	32.9	31.9	31.8	31.4	31.5	31.0	32.1	31.1	31.4	0
33.3	32.4	32.5	34.2	33.7	33.4	32.8	32.1	32.2	31.6	31.0	30.8	32.8	31.9	31.6	31.2	30.8	30.7	1
34.2	33.2	33.9	34.0	34.3	33.5	33.2	33.5	33.2	32.6	32.3	32.6	32.1	33.0	32.3	31.6	31.0	32.3	1
35.7	34.5	34.6	34.7	33.7	35.0	34.8	35.2	34.7	35.4	33.9	33.9	34.0	34.8	34.4	34.4	34.9	33.9	0
33.4	34.0	33.8	33.9	33.5	33.9	33.1	33.1	33.5	32.1	32.3	32.3	32.4	31.8	31.7	31.3	31.2	32.2	0
35.5	34.6	33.6	34.4	34.7	34.2	33.6	33.6	33.5	33.5	33.2	32.7	32.6	32.8	32.2	31.3	30.9	32.2	1
34.8	34.0	34.1	34.4	34.3	33.8	33.9	33.9	34.2	32.1	31.5	31.5	32.0	31.4	31.7	31.0	30.6	31.2	0
35.7	34.4	34.4	34.2	34.7	34.2	34.1	35.1	35.6	34.4	33.6	32.9	33.8	33.3	33.0	33.3	34.5	34.6	1
33.9	33.0	33.1	33.3	32.8	33.5	33.0	32.5	32.7	31.9	31.2	31.9	31.6	31.9	31.8	32.4	30.3	30.9	0

Рисунок 7 – Пример данных температурных данных компьютерного моделирования, где в столбце «target» здоровые — «0», больные — «1»

3.2 Частотный анализ классифицируемых данных

Перед классификацией температурных данных был проведен частотный анализ для исследования распределения температуры в зависимости от того, в какой точке она была замерена и есть ли у данной модели опухоль. Частотный анализ был произведен с помощью библиотеки Pandas, а графическое отображение результатов с помощью Matplotlib. Точки, которые были проанализированы соответствуют точкам на схеме измерений согласно методу РТМ (рисунок 6). Код программы для отображения результатов частотного анализа находится в приложении (листинг А.2).

Сначала для исследования была взята точка 0ртм. Результаты исследования представлены в виде диаграммы частот (рисунок 8), где верхняя диаграмма – это здоровые пациенты, а нижняя – больные.




Рисунок 8 – Диаграмма частот температур в точке 0ртм. Верхняя диаграмма — здоровые пациенты, нижняя — больные

Изучив диаграммы, можно заметить, что в данной точке у пациентов чаще встречаются более высокие температуры, нежели у здоровых. Точка 0ртм больше всего подвержена воздействию от опухоли в температурном смысле, так как находится ровно в центре молочной железы.

Следующей для исследования была рассмотрена точка 3ртм, диаграмма частот температур которой представлена на рисунке 9. Для данной точки можно наблюдать схожую картину с точкой 0ртм – тут так же больше значе-

ний со средней температурой у больных пациентов, несмотря на то, что эта точка не является центральной.




Рисунок 9 – Диаграмма частот температур в точке Зртм. Верхняя диаграмма — здоровые пациенты, нижняя — больные

Также была рассмотрена точка 7ртм, для которой как видно из диаграммы частот температур (рисунок 10) ситуация аналогична с точками 0ртм и Зртм.




Рисунок 10 – Диаграмма частот температур в точке 7ртм. Верхняя диаграмма — здоровые пациенты, нижняя — больные

3.3 Результаты классификации моделей с опухолью радиусом 0.5 см

Для моделей с разными размерами опухоли отдельно была посчитана точность определения класса и построены круговые диаграммы для наглядности, где как «1» отмечены верно классифицированные модели, а как «0» —

неверно классифицированные.

Как видно из диаграммы на рисунке 11, для моделей с радиусом опухоли 0.5 см лучший результат показал метод SVM, точность определения классов которого равна 57.5%. Хуже всего для данных моделей показал себя наивный байесовский классификатор с точностью классификации 27.5%



Рисунок 11 – Диаграммы с точностью определения класса для трех методов классификации моделей с размером опухоли $R=0.5$ см («1» – классифицировано верно, «0» – классифицировано неверно)

3.4 Результаты классификации моделей с опухолью радиусом 0.75 см

Рассмотрим результаты классификации для моделей с радиусом опухоли 0.75 см (рисунок 12). Как видно из диаграмм, для данных моделей наивный байесовский классификатор сработал лучше, для для моделей с радиусом опухоли 0.5 см, показав результат точности равный 70%. Точность определения классов методом SVM опять оказалась лучше, чем у остальных – 72.5

Исходя из этого, можно сделать вывод, что точность классификации сильно зависит от размеров опухоли и выбранного алгоритма классификации.



Рисунок 12 – Диаграммы с точностью определения класса для трех методов классификации моделей с размером опухоли $R=0.75$ см («1» – классифицировано верно, «0» – классифицировано неверно)

3.5 Результаты классификации для всех моделей вместе

В качестве заключительного эксперимента было принято решение смешать вместе данные моделей с радиусом 0.5 см и 0.75 см. В качестве обучающей выборки использовались 180 моделей, а в качестве тестовой – 60 моделей. После чтения из файла данные были перемешаны между собой.

Результаты представлены на диаграмме (рисунок 12). В этот раз лучшим по точности определения класса стал наивный байесовский классификатор с точностью 70%, которая не изменилась по сравнению с предыдущим экспериментом. А метод SVM, показавший лучший результат в предыдущих двух экспериментах, в этот раз определил классы моделей с точностью 66.7%, такой же как и метод k-ближайших соседей.



Рисунок 13 – Диаграммы с точностью определения класса для трех методов классификации моделей с размером опухоли $R=0.5$ см и $R=0.75$ см вместе («1» – классифицировано верно, «0» – классифицировано неверно)

Заключение

В данной работе были рассмотрены некоторые из популярных библиотек языка программирования Python для решения задач машинного обучения. Был описан принцип работы таких алгоритмов классификации как метод опорных векторов (SVM), k-ближайших соседей и наивный байесовский классификатор.

Реализована программа для классификации данных компьютерного моделирования яркостной температуры на языке Python с помощью библиотеки Scikit-learn. Температурные данные были разбиты на обучающую и тестовую выборки и классифицированы с помощью получившейся программы.

Исходя из результатов классификации моделей был сделан вывод, что точность классификации данных сильно зависит от используемого алгоритма и размеров опухоли. Причем, если использовать все данные вместе – то результат сильно отличается от экспериментов, проведенных для каждого размера опухоли отдельно. Лучше всего в проведенных экспериментах себя показал метод опорных векторов (SVM) и наивный байесовский классификатор.

Список литературы

1. Bardati, F. Modeling the Visibility of Breast Malignancy by a Microwave Radiometer / F. Bardati, S. Iudicello. – Текст : непосредственный // Biomed. Engineering. – 2008. – Vol.55 (6). – С. 214-221.
2. Cristianini, T. An Introduction to Support Vector Machines and Other Kernel-based Learning Methods / Nello Cristianini, John Shawe-Taylor. – Текст : непосредственный // Cambridge University Press. – 2000. – 204 с.
3. Crammer, K. On the algorithmic implementation of multiclass kernel-based vector machines / Koby Crammer, Yoram Singer. – Текст : непосредственный // Journal of Machine Learning Research. – 2002. – № 2. – С. 265–292.
4. Fear, K.E. Microwave detection of breast cancer / K.E. Fear, M. Stuchly. – Текст : непосредственный // IEEE Trans. Microwave Theory Tech. – 2000. – Vol.48 (11). – С. 1854-1863.
5. Hetal, B. An Empirical Evaluation of Data Mining Classification Algorithms / He-tal Bhavsar, Amit Ganatra. – Текст : непосредственный // International Journal of Computer Science and Information Security (IJCSIS). – 2016 – № 5. – С. 142–150.
6. Kumbhar, S. Comparative Analysis of Classification Algorithms / Vijaykumar S. Kumbhar. – Текст : электронный // NCORTIT. – 2017. – 5 С. – URL: <https://www.researchgate.net/publication/313440536>, свободный. — Загл. с экрана.
7. Leroy, Y. Non-invasive microwave radiometry thermometry / Y. Leroy, B. Bosquet, A. Mammouni. – Текст : непосредственный // Physiol. Means. – 1998. – Vol.19. – С. 127-148.
8. Mirmozaffari, M. Data Mining Classification Algorithms for Heart Disease Prediction / Mirpouya Mirmozaffari, Alireza Alinezhad, Azadeh Gilanpour. – Текст : непосредственный // International Journal of Computing

- Communications & Instrumentation Engg (IJCCIE). – 2017. – 4, № 1 – С. 11-15.
9. Mossina, L. Naive Bayes Classification for Subset Selection / Luca Mossina, Emmanuel Rachelson. – Текст : электронный // Physiol. Means. – 1998. – Vol.19. – С. 127-148. – URL: <https://www.researchgate.net/publication/318560282>, свободный. — Загл. с экрана.
 10. Sherwood, L. Fundamentals of Human Physiology / L. Sherwood. – Текст : непосредственный // Belmon : Brooks/Cole – 2012. – 720 с.
 11. Statnikov, A. A Gentle Introduction to Support Vector Machines in Biomedicine: Theory and methods / Alexander Statnikov, Constantin F. Aliferis, Douglas P. Hardin. – Текст : непосредственный // World Scientific. – 2011. – 183 с.
 12. Stauffer, P.R. Utility of Microwave Radiometry for Diagnostic and Therapeutic Applications of Non-Invasive Temperature Monitoring / P.R. Stauffer, D.R. Rodrigues. – Текст : непосредственный // IEEE BenMAS (Benjamin Franklin Symposium on Microwave and Antenna Sub-systems). – 2014. – С. 1-3.
 13. Van Ongeval, Ch. Digital mammography for screening and diagnosis of breast cancer: an overview / Ch. Van Ongeval. – Текст : непосредственный // PubMed PMID. – 2007. – Vol. 90 (3). – С. 163–166.
 14. Айвазян, С. Прикладная статистика: классификация и снижение размерности / Айвазян С. А., Бухштабер В. М., Енюков И. С., Мешалкин Л. Д. – Текст : непосредственный // Москва : Финансы и статистика, 1989. – 487 с.
 15. Алгоритмы интеллектуального анализа данных. / Текст : электронный // 2015. – URL: <https://tproger.ru/translations/top-10-data-mining-algorithms/>, свободный. — Загл. с экрана.

16. Барсегян, А. Методы и модели анализа данных: OLAP и Data Mining / А.А. Барсегян, М.С. Куприянов, В.В. Степаненко, И.И. Холод. – Текст : непосредственный // Санкт-Петербург : БХВ-Петербург, 2004. – 336 с.
17. Бирюлин, Г. Теплофизический расчет в конечно-элементном пакете COMSOL/FEMLAB : методическое пособие / Г.В. Бирюлин. – Текст : непосредственный // Санкт-Петербург : СПбГУИТМО, 2006. – 75 с.
18. Вандер Плас, Д. Python для сложных задач. Наука о данных и машинное обучение / Дж. Вандер Плас. – Текст : непосредственный // Санкт-Петербург : Питер, 2017. – 576 с.
19. Веснин, С. Современная микроволновая радиотермометрия молочных желез / С.Г. Веснин, М.А. Каплан, Р.С. Авакян. – Текст : электронный // Маммология/Онкогинекология. – 2008. – №3 – 8 с. – URL: <https://elibrary.ru/item.asp?id=11610722>, свободный. — Загл. с экрана.
20. Веснин, С. Разработка серии антенн-аппликаторов для неинвазивного измерения температуры тканей организма человека при различных патологиях / С.Г. Веснин, М.К. Седанкин. – Текст : электронный // Вестник МГТУ им. Н.Э. Баумана. Сер. «Естественные науки». – 2012. – №11 – С. 43-61. – URL: <https://elibrary.ru/item.asp?id=20179995>, свободный. — Загл. с экрана.
21. Вьюгин, В. Математические основы теории машинного обучения и прогнозирования / Владимир Вьюгин. – Текст : электронный // МЦМНО. – 2013. – 390 с.
22. Гудфеллоу, Я. Глубокое обучение / Гудфеллоу Я., Бенджио И., Курвилль А. – Текст : электронный // Москва : ДМК Пресс. – 2017. – 652 с.
23. Дауни, А. Байесовские модели / Дауни А.Б., пер. с англ. В. А. Яроцкого – Текст : непосредственный // Москва : ДМК Пресс. – 2018. – 182 с.
24. Доусон, М. Програмируем на Python / Доусон М. – Текст : непосредственный // Санкт-Петербург : Питер. – 2019. – 416 с.

25. Журавлев, Ю. «Распознавание». Математические методы. Программная система. Практические применения / Журавлев Ю. И., Рязанов В. В., Сенько О. В. – Текст : непосредственный // Москва : Фазис, 2006. – 176 с.
26. Левитин, А. Алгоритмы. Введение в разработку и анализ / Левитин А. В. – Текст : непосредственный // Москва : Вильямс. – 2006. – 576 с.
27. Лосев, А. Проблемы измерения и моделирования тепловых и радиационных полей в биотканях: анализ данных микроволновой термометрии / А.Г. Лосев, А.В. Хоперсков, А.С. Астахов, Х.М. Сулейманова. – Текст : непосредственный // Вестн. Волгогр. гос. ун-та. Сер. 1, Мат. Физ. – 2015. – No 6 – 41 с.
28. МакГрат, М. Алгоритмы. Python. Программирование для начинающих / Майк МакГрат. – Текст : непосредственный // Эксмо. – 2013. – 194 с.
29. Мюллер, А. Введение в машинное обучение с помощью Python. Руководство для специалистов по работе с данными / Андреас Мюллер, Сара Гвидо. – Текст : непосредственный // Вильямс. – 2017. – 480 с.
30. Николенко, С. Алгоритмы. Глубокое обучение / Николенко С., Кадуринов А., Архангельская Е. – Текст : непосредственный // Санкт-Петербург : Питер. – 2018. – 480 с.
31. Паклин, Н. Бизнес-аналитика: от данных к знаниям : Учебное пособие / Паклин Н.Б., Орешков В.И. – Текст : непосредственный // Санкт-Петербург : Питер, 2013. – 2-е изд. – 704 с.
32. Потапов, М. Анализ эффективности алгоритмов интеллектуального анализа данных для решения задачи распознавания изображений со спутников / Потапов М. П. – Текст : электронный // Федеральное государственное бюджетное образовательное учреждение высшего образования "Сибирский государственный университет науки и технологий имени академика М.Ф. Решетнева": Актуальные проблемы авиации и космонавтики, 2016. – 1. – № 12 – С. 563-565.

33. Рашка, С. Python и машинное обучение / Рашка С., пер. с англ. А. В. Логунова. – Текст : непосредственный // Москва : ДМК Пресс, 2017. – 418 с.
34. Розенблатт, Ф. Принципы нейродинамики: Перцептроны и теория механизмов мозга / Розенблатт Ф. – Текст : непосредственный // Москва : Мир, 1965. – 480 с.
35. Флах, П. Машинное обучение / Флах П. – Текст : непосредственный // Москва : ДМК Пресс, 2015. – 400 с.
36. Шлезингер, М. Десять лекций по статистическому и структурному распознаванию / Шлезингер М., Главач В. – Текст : непосредственный // Киев : Наукова думка, 2004. – 546 с.

Приложение А

(обязательное)

Программный код

Листинг А.1 – Код программы для классификации данных компьютерного моделирования яркостной температуры

```
import numpy as np
import pandas as pd
from sklearn import svm
import matplotlib.pyplot as plt
from sklearn import neighbors
from sklearn.naive_bayes import GaussianNB
from sklearn.utils import shuffle
modelFolder = '075'
def calcParams(testing, predict):
    zdorovieTesting = 0
    bolnieTesting = 0
    for item in testing:
        if item == 0:
            zdorovieTesting += 1
        else:
            bolnieTesting += 1
    zdoroviePredict = 0
    bolniePredict = 0
    for item in predict:
        if item == 0:
            zdoroviePredict += 1
        else:
            bolniePredict += 1
    chuvstv = bolniePredict / bolnieTesting
    specifich = zdoroviePredict / zdorovieTesting
    return chuvstv, specifich

data = pd.read_csv(modelFolder + '/data.csv',
    delimiter=',',
    names=['0рtm', '1рtm', '2рtm', '3рtm', '4рtm', '5рtm', '6рtm', '7рtm', '8рtm',
    '0ик', '1ик', '2ик', '3ик', '4ик', '5ик', '6ик', '7ик', '8ик', 'target'])
trainingTemperatures = data[['0рtm', '1рtm', '2рtm', '3рtm', '4рtm', '5рtm',
```

```

'6рtm', '7рtm', '8рtm', '0ик', '1ик', '2ик', '3ик', '4ик', '5ик', '6ик',
'7ик', '8ик']]
trainingTemperatures = shuffle(trainingTemperatures)
trainingTemperatures.reset_index(inplace=True, drop=True)
data.head()
testingData = pd.read_csv(modelFolder + '/testing.csv',
delimiter=',',
names=['0рtm', '1рtm', '2рtm', '3рtm', '4рtm', '5рtm', '6рtm', '7рtm', '8рtm',
'0ик', '1ик', '2ик', '3ик', '4ик', '5ик', '6ик', '7ик', '8ик', 'target'])
testingTemperatures = testingData[['0рtm', '1рtm', '2рtm', '3рtm', '4рtm',
'5рtm', '6рtm', '7рtm', '8рtm', '0ик', '1ик', '2ик', '3ик', '4ик', '5ик',
'6ик', '7ик', '8ик']]

#SVM
clf = svm.SVC(gamma='scale')
clf.fit(trainingTemperatures, data.target)

classes = clf.predict(testingTemperatures)

testingData.target
res = testingData.target == classes
trueCount = 0
for el in res:
if el == True:
trueCount += 1

print('Правильно определено:', trueCount, '\nНеправильно:', len(res) - trueCount)
chuvstv, specifich = calcParams(testingData.target, classes)
print('Чувствительность:', chuvstv, '\nСпецифичность:', specifich);

labels = 'Совпадает', 'Не совпадает'
values = [trueCount, len(res) - trueCount]
explode = (0.1, 0)

fig1, ax1 = plt.subplots()
ax1.pie(values, labels=labels, autopct='%1.1f%%',
shadow=True, startangle=90)
ax1.axis('equal')

plt.show()

```

```

#KNN
clf = neighbors.KNeighborsClassifier(20, weights='uniform')
clf.fit(trainingTemperatures, data.target)

classes = clf.predict(testingTemperatures)

testingData.target
res = testingData.target == classes
trueCount = 0
for el in res:
    if el == True:
        trueCount += 1

print('Правильно определено:', trueCount, '\nНеправильно:', len(res) - trueCount)
chuvstv, specifich = calcParams(testingData.target, classes)
print('Чувствительность:', chuvstv, '\nСпецифичность:', specifich);

labels = 'Совпадает', 'Не совпадает'
values = [trueCount, len(res) - trueCount]
explode = (0.1, 0)

fig1, ax1 = plt.subplots()
ax1.pie(values, labels=labels, autopct='%1.1f%%',
shadow=True, startangle=90)
ax1.axis('equal')

plt.show()

#NB
gnb = GaussianNB()
clf = gnb.fit(trainingTemperatures, data.target)

classes = clf.predict(testingTemperatures)

testingData.target
res = testingData.target == classes
trueCount = 0
for el in res:
    if el == True:

```

```

trueCount += 1

print('Правильно определено:', trueCount, '\nНеправильно:', len(res) - trueCount)
chuvstv, specifich = calcParams(testingData.target, classes)
print('Чувствительность:', chuvstv, '\nСпецифичность:', specifich);

labels = 'Совпадает', 'Не совпадает'
values = [trueCount, len(res) - trueCount]
explode = (0.1, 0)

fig1, ax1 = plt.subplots()
ax1.pie(values, labels=labels, autopct='%1.1f%%',
shadow=True, startangle=90)
ax1.axis('equal')

plt.show()

```

Листинг А.2 – Код программы для отображения результатов частотного анализа

```

import numpy as np
import pandas as pd
from sklearn import svm
import matplotlib.pyplot as plt
import matplotlib
from sklearn import neighbors
from sklearn.naive_bayes import GaussianNB
from collections import Counter
from collections import OrderedDict
from scipy.interpolate import spline

modelFolder = 'all'
data = pd.read_csv(modelFolder + '/data.csv',
delimiter=',',
names=['0рtm', '1рtm', '2рtm', '3рtm', '4рtm', '5рtm', '6рtm', '7рtm', '8рtm',
'0ик', '1ик', '2ик', '3ик', '4ик', '5ик', '6ик', '7ик', '8ик', 'target'])

point = '0рtm'
filter1 = data.target == 0

```



```

fr1 = OrderedDict(sorted(dict(Counter(data.loc[filter1][point])).items()))
names1 = list(fr1.keys())
values1 = list(fr1.values())

x_smooth1 = np.linspace(min(names1), max(names1), 50)
y_smooth1 = spline(names1, values1, x_smooth1)

filter2 = data.target == 1
fr2 = OrderedDict(sorted(dict(Counter(data.loc[filter2][point])).items()))
names2 = list(fr2.keys())
values2 = list(fr2.values())

x_smooth2 = np.linspace(min(names2), max(names2), 50)
y_smooth2 = spline(names2, values2, x_smooth2)

fig, axs = plt.subplots(2, 1, figsize=(10, 10), sharey=True)
plt.subplots_adjust(wspace=0, hspace=0.17)
axs[0].bar(names1, values1)
#axs[0].plot(x_smooth1, y_smooth1, color='tab:orange')
axs[0].tick_params(axis='both', which='major', labelsize=15)
axs[0].set_title('Здоровые пациенты')

axs[1].bar(names2, values2)
#axs[1].plot(x_smooth2, y_smooth2, color='tab:orange')
axs[1].tick_params(axis='both', which='major', labelsize=15)
axs[1].set_title('Больные пациенты')
plt.savefig(point + '.png')
plt.show()

```

Приложение Б
(обязательное)
Лист задания

Федеральное государственное автономное
образовательное учреждение высшего образования
«Волгоградский государственный университет»
институт Математики и информационных технологий
кафедра Информационных систем и компьютерного моделирования

УТВЕРЖДАЮ
Руководитель направления
09.03.01 Информатика и
вычислительная техника

« ____ » _____ 201__ г.
Е.О. Агафонникова

ЗАДАНИЕ
на выполнение научно-исследовательской работы

студента Борисовского Егора Ивановича группы ИВТ-161

- 1) Тема: Программная реализация классификатора данных на языке Python.
- 2) Цель: Реализация программы для классификации температурных данных на языке Python и исследование влияния размеров опухоли и используемого алгоритма на точность классификации.
- 3) Основные задачи:
 - а) изучить алгоритмы классификации и выбрать подходящие под текущую задачу;
 - б) рассмотреть и выбрать библиотеки с реализацией выбранных алгоритмов;
 - в) реализовать программу для классификации результатов компьютерного моделирования;
 - г) исследовать влияние размеров опухоли на точность классификации;
 - д) написать пояснительную записку по результатам выполнения работы в издательской системе LaTeX.
- 4) Основные этапы выполнения работы:
 - а) Глава 1. Алгоритмы классификации данных;
 - б) Глава 2. Разработка программы для классификации с использованием библиотеки Scikit-learn.
 - в) Глава 3. Классификация температурных данных компьютерного моделирования.
- 5) Рекомендуемая литература:
 - а) Hetal Bhavsar, Amit Ganatra, An Empirical Evaluation of Data Mining Classification Algorithms, International Journal of Computer Science and Information Security (IJCSIS), 14, no. 5, (2016), 142–150.

- б) (PDF) Data mining classification algorithms. Available from: https://www.researchgate.net/publication/338019767_Data_mining_classification_algorithms [accessed Dec 24 2019].
- в) Мюллер, А. Введение в машинное обучение с помощью Python. / А. Мюллер, С. Гвидо. // ИЦ «Гевиста». – 2017. – 393 с.
- г) Веснин, С. Г. Современная микроволновая радиотермометрия молочных желез. / С. Г. Веснин, М. А. Каплан, Р. С. Авакян. // Маммология/Онкогинекология. – 2008. – №3. – 8 с.
- д) Лосев, А. Г. Интеллектуальный анализ термометрических данных в диагностике молочных желез / А. Г. Лосев, В. В. Левшинский // Управление большими системами. – 2017. – Вып. 70. – С. 113–135.
- е) Ясницкий, Л. Н. Введение в искусственный интеллект : учебн. пособие для студ. вузов / Л. Н. Ясницкий. // М. : Academia, 2005. – 176 с.

Дата выдачи _____ Срок выполнения _____

Руководитель _____ проф., д.ф.-м.н. А.В. Хоперсков
(подпись)

Задание принял к исполнению _____
(подпись)